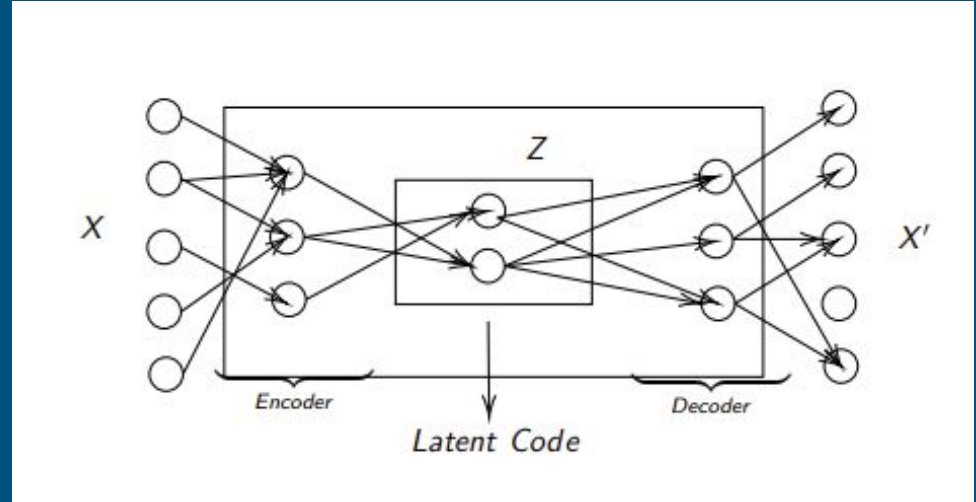




TP5: Deep Learning


Introducción

- Autoencoders
 - no-lineal
 - Generacional
 - Denoising
 - Variacional



Implementación Autoencoder, EL en 2D

- Se planteó un Autoencoder con 2d en el espacio latente que aprende el conjunto de caracteres
- Se compararon distintas estructuras del Autoencoder y técnicas de optimización del aprendizaje
- Se graficó el Espacio latente
- Se generaron nuevas letras no pertenecientes al conjunto de entrenamiento




Primera Implementación del Autoencoder

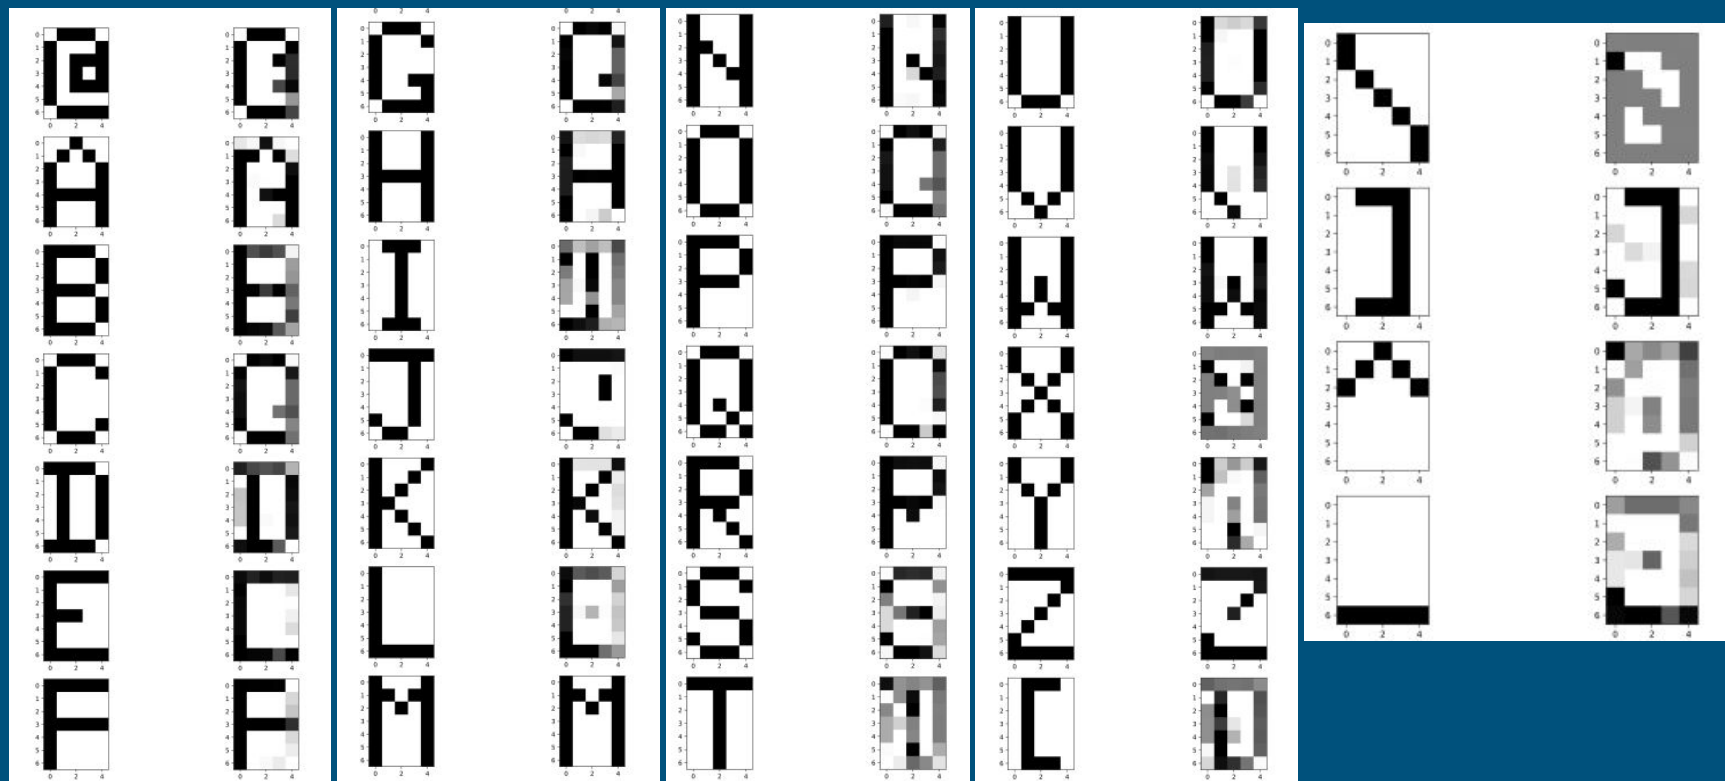
- Estructura de [35, 20, 2, 20, 35]
- Activación ["relu","lineal","relu", "sigmoid"]
- Método de 'Powell' para optimizar
- Error: 37.837 (SSE)



Error vs Iteraciones



Aprendizaje




Segunda Implementación del Autoencoder


- Estructura de [35, 20, 10, 2, 10, 20, 35]
- Activación ["relu","relu","lineal","relu","relu", "sigmoid"]
- Método de 'Powell' para optimizar
- Error: 7.905 (SSE)
- 700 Iteraciones




Error (SSE) vs Iteraciones



Aprendizaje



Datos de entrada en el espacio latente

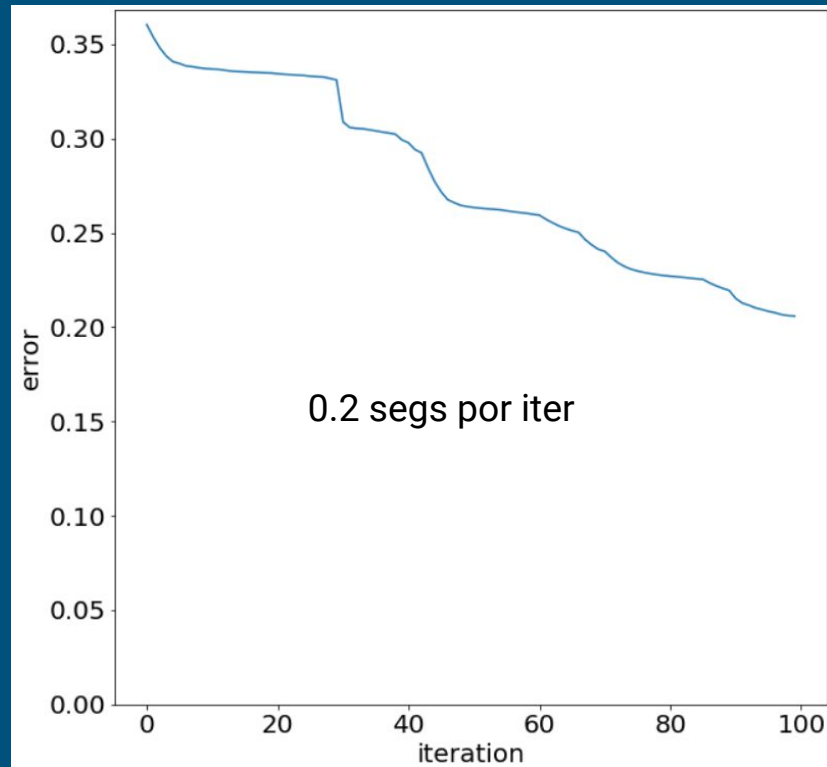
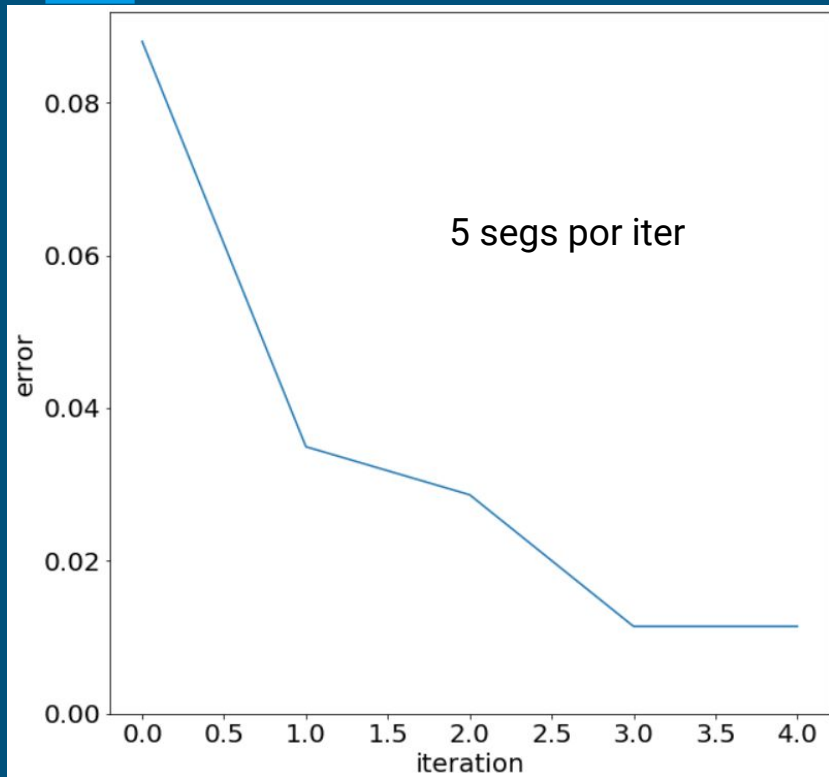


Generación de letras analizando el espacio latente

- Utilizando un subconjunto de los datos, se entrenó a la red
- Seleccionando dos puntos en el espacio latente, se generaron letras nuevas sobre la recta que los une





Powell vs Gradiente conjugado (MSE)





Gradiente Conjugado

Estructura: 35 - 10 - 2 - 10 - 35




Powell

Estructura: 35 - 10 - 2 - 10 - 35



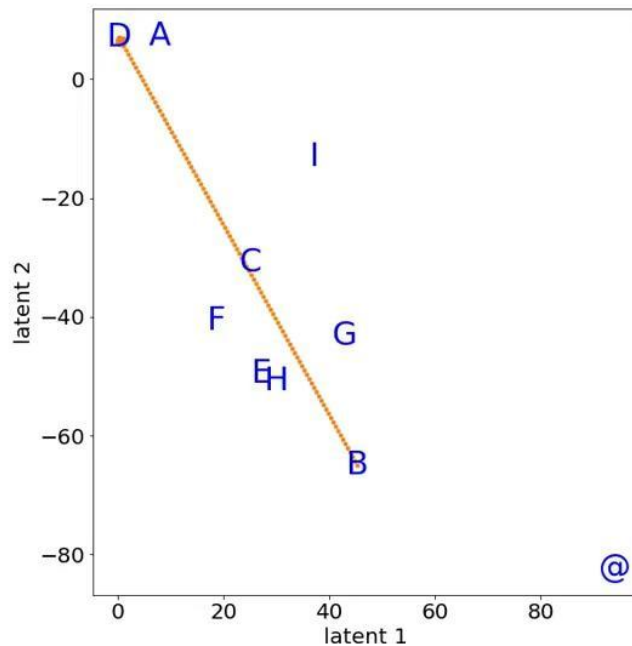
Powell

Estructura: 35 - 20 - 10 - 2 - 10 - 20 - 35




Powell

Estructura: 35 - 20 - 10 - 2 - 10 - 20 - 35



Powell

Estructura: 35 - 20 - 10 - 2 - 10 - 20 - 35



Conclusiones 1 A



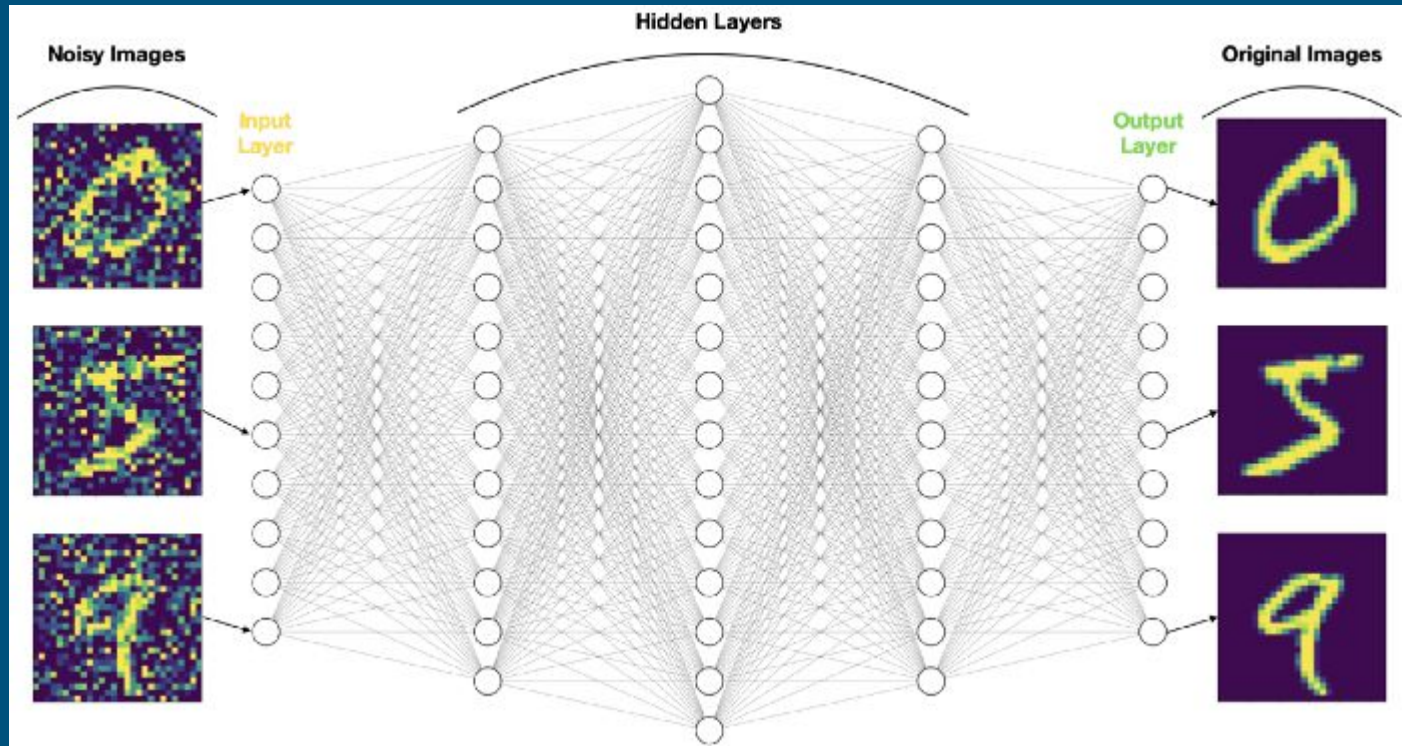
- Al agregar más capas “baja el error”
 - Hay más direcciones para “moverse”
 - Tarda significativamente más en ejecutar
- No se encontró una estructura ideal para el problema, se fueron probando diferentes arquitecturas con diferentes capas y diferentes activaciones
- Las transiciones entre espacios vecinos son “suaves”

Denoising Autoencoder

- Sobre el mismo dataset, implementamos una variante que implementa un "Denoising Autoencoder".
- Especificamos la estructura elegida y porqué
- Generamos ruido y analizamos su capacidad de eliminarlo



Denoising autoencoder




Denoising Autoencoder, Implementación

- Usamos la estructura de [35, 55, 35]
- Activación ["lineal", "sigmoid"]
- error = $2.86e-03$ (MSE)
- muestras de ruido por letra = 3
- probabilidad de flip : 10%
- 10 Elementos



Denoising Autoencoder



probabilidad de flip : 20%



Eliminar ruido

N=10



estructura: 35 - 55 - 35



Eliminar ruido

N=10

estructura: 35 - 55 - 35




Conclusiones 1 B

- Se usó una arquitectura con un espacio latente de mayor dimensionalidad así “sobrecompleta” el ruido
- Es un estilo del SAE que ayuda a discriminar los datos, por ende clasifica mejor a las entradas con ruido en sus respectivas categorías
- Es capaz de asociar una letra ruidosa con su valor verdadero
- Mayor es el ruido más costoso es el aprendizaje



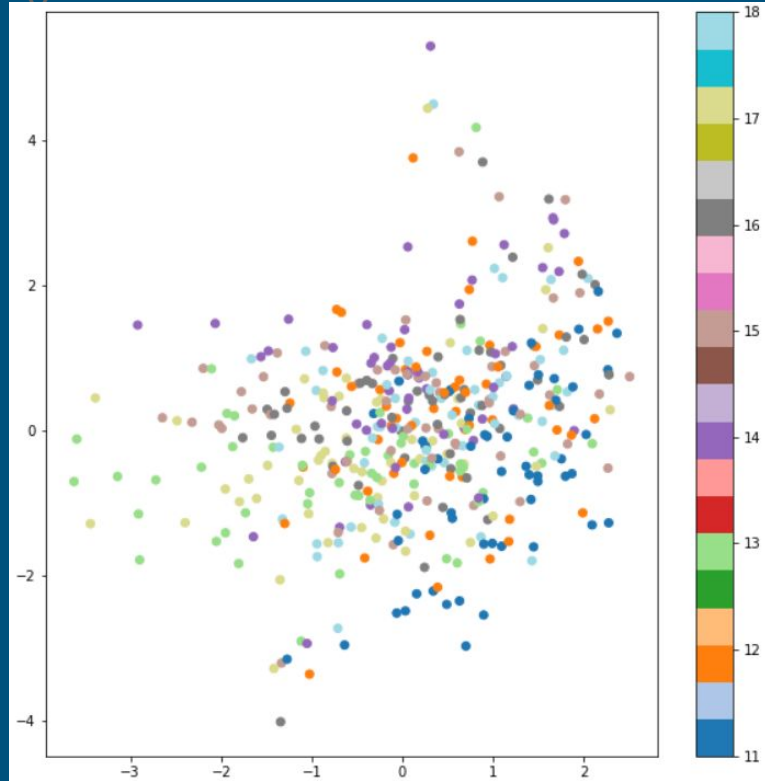
Implementación Autoencoder VAE (Keras)



- Agregamos ruido a el conjunto de letras (20 letras) del ejercicio 1 y lo probamos con otro conjunto con ruido.
- Batch size = 10
- Capa intermedia = 20
- épocas = 50
- ruido 0.1 de probabilidad por pixel




Implementación Autoencoder VAE (Keras)



- Tomamos un dataset de internet “English Handwritten Characters”
- Batch size = 10
- Capa intermedia = 256
- épocas = 1000



Implementación Autoencoder VAE (Keras)



Conclusiones 2

- Se ve como el VAE logra explorar el espacio latente y dividirlo en sus clases correspondientes
 - A diferencia del ejercicio anterior, donde letras parecidas podían estar separadas, ahora el VAE se entrena para que estén cercanas en el espacio latente
- Se puede ver que es posible crear nuevas muestras a partir del espacio latente

